

ДИСПЕРСИОННЫЙ АНАЛИЗ

Однофакторный дисперсионный анализ

Во многих практических ситуациях представляет интерес влияние того или иного фактора на рассматриваемый признак.

Пусть, например, оценка качества поверхности детали проводится с помощью l приборов и необходимо исследовать влияние фактора «прибор» на результат измерений. Если приборов два, то проверка нулевой гипотезы о равенстве их средних показаний проводится обычными методами проверки статистических гипотез. Если же $l > 2$, то используются методы дисперсионного анализа.

Проверяется нулевая гипотеза $H_0: m_1 = m_2 = \dots = m_l$ об отсутствии влияния на результативный признак X фактора A , имеющего l уровней A_k , $k = 1, \dots, l$. Основная идея дисперсионного анализа состоит в том, чтобы сопоставить дисперсию за счет воздействия фактора A с дисперсией, обусловленной случайными причинами. Если различие между ними не существенно, то влияние фактора A на признак X незначительно. Если же различие между факторной и остаточной дисперсиями значимо, то это говорит о влиянии фактора A на рассматриваемый признак X .

Предполагается, что случайная величина X имеет нормальное распределение с математическим ожиданием m_k , зависящим от уровня фактора A_k , и постоянной дисперсией σ^2 . В качестве исходных данных используются выборочные значения величины X , полученные для каждого уровня фактора A ; число элементов выборки на каждом уровне равно n , тогда общее число наблюдений nl , x_{ik} - результат

| номер опыта | Уровни фактора А | | | | |
|----------------|------------------|-----------------|-------------------------|-----------------|--|
| | A1 | A2 | ... A _k ... | A _l | |
| 1 | X ₁₁ | X ₁₂ | ... X _{1k} ... | X _{1l} | |
| 2 | X ₂₁ | X ₂₂ | ... X _{2k} ... | X _{2l} | |
| ... | ... | ... | ----- | ... | |
| i | X _{i1} | X _{i2} | ... X _{ik} ... | X _{il} | |
| ... | ... | ... | ----- | ... | |
| n | X _{n1} | X _{n2} | ... X _{nk} ... | X _{nl} | |

i -го наблюдения ($i=1, \dots, n$) за k -тым уровнем фактора A ($k=1, \dots, l$).

Выборочная средняя, соответствующая k -му уровню фактора A , (групповая средняя) вычисляется по формуле:

$$\bar{x}_k = \frac{1}{n} \sum_{i=1}^n x_{ik}; \quad (3.1)$$

общая выборочная средняя есть

$$\bar{x} = \frac{1}{nl} \sum_{k=1}^l \sum_{i=1}^n x_{ik} = \frac{1}{l} \sum_{k=1}^l \bar{x}_k. \quad (3.2)$$

Для вычисления дисперсии найдем суммы квадратов.

Общая сумма квадратов – это сумма квадратов отклонений наблюдаемых значений x_{ik} от общей выборочной средней:

$$Q = \sum_{k=1}^l \sum_{i=1}^n (x_{ik} - \bar{x})^2 = \sum_{k=1}^l \sum_{i=1}^n x_{ik}^2 - nl\bar{x}^2. \quad (3.3)$$

Факторная сумма квадратов (обусловленная влиянием фактора A) - это сумма квадратов отклонений групповых средних от общей средней:

$$Q_A = n \sum_{k=1}^l (\bar{x}_k - \bar{x})^2 = n \sum_{k=1}^l \bar{x}_k^2 - nl\bar{x}^2. \quad (3.4)$$

Остаточная сумма квадратов характеризует рассеяние внутри группы:

$$Q_e = \sum_{k=1}^l \sum_{i=1}^n (x_{ik} - \bar{x}_k)^2. \quad (3.5)$$

На практике эта сумма определяется из основного тождества дисперсионного анализа, в соответствии с которым

$$Q = Q_A + Q_e. \quad (3.6)$$

Разделив суммы квадратов на соответствующее число степеней свободы, найдем соответствующие дисперсии (иногда их называют средними суммами квадратов):

$$\begin{aligned} S^2 &= \frac{Q}{nl-1}, \\ S_A^2 &= \frac{Q_A}{l-1}, \\ S_e^2 &= \frac{Q}{l(n-1)}. \end{aligned} \quad (3.7)$$

Если нулевая гипотеза о равенстве средних справедлива, то эти дисперсии являются несмещенными оценками дисперсий генеральной совокупности. Значительное превышение дисперсии S_A^2 над дисперсией S_e^2 можно объяснить различием средних в группах. Поэтому для проверки нулевой гипотезы используется отношение этих средних, которое имеет распределение Фишера

$$F = \frac{S_A^2}{S_e^2} = \frac{\frac{1}{l-1} Q_A}{\frac{1}{l(n-1)} Q_e} \quad (3.8)$$

с числом степеней свободы $(l-1)$ и $l(n-1)$. Гипотеза $H_0: m_1 = m_2 = \dots = m_l$ не противоречит результатам наблюдений при заданном уровне значимости α , если

$$F > F_{1-\alpha}(l-1, l(n-1)),$$

в этом случае считается, что фактор A не оказывает существенного влияния на признак X .

Результаты расчета обычно сводятся в таблицу.

| Источник дисперсии | Сумма квадратов | Число степеней свободы | Дисперсия | Выборочное значение статистики Фишера |
|--------------------|-----------------|------------------------|-----------|---------------------------------------|
| Фактор A | Q_A | $l - 1$ | S_A^2 | F |
| Остаток | Q_e | $l(n - 1)$ | S_e^2 | |
| Общая | Q | $ln - 1$ | S^2 | |

3.2.

Многофакторный дисперсионный анализ

В двухфакторном дисперсионном анализе проверяется влияние на результативный признак X двух факторов A и B и их взаимодействия. Фактор A имеет l уровней A_j , $j = 1, \dots, l$; фактор B – r уровней B_k , $k = 1, \dots, r$. При каждом сочетании уровней $A_j B_k$ делается n наблюдений. Общее число наблюдений nlr .

Проверяются три нулевые гипотезы: об отсутствии влияния на результативный признак X фактора A , фактора B и их взаимодействия AB .

Пусть X_{ijk} – результат i -го наблюдения ($i = 1, \dots, n$) при j -ом уровне фактора A и k -ом уровне фактора B . Тогда средняя, соответствующая сочетанию уровней A и B :

$$\bar{x}_{jk} = \frac{1}{n} \sum_{i=1}^n x_{ijk};$$

средняя, соответствующая уровню A_j :

$$\bar{x}_{0j} = \frac{1}{nr} \sum_{i=1}^n \sum_{k=1}^r x_{ijk} = \frac{1}{r} \sum_{k=1}^r \bar{x}_{jk};$$

средняя, соответствующая уровню B_k :

$$x_{k0} = \frac{1}{nl} \sum_{i=1}^n \sum_{j=1}^l x_{ijk} = \frac{1}{l} \sum_{j=1}^l \bar{x}_{jk},$$

общая средняя

$$\bar{x} = \frac{1}{nlr} \sum_{i=1}^n \sum_{j=1}^l \sum_{k=1}^r x_{ijk} = \frac{1}{l} \sum_j \bar{x}_{0j} = \frac{1}{r} \sum_{k=1}^r x_{k0}.$$

По аналогии с однофакторным анализом справедливо тождество

$$Q = Q_A + Q_B + Q_{AB} + Q_e,$$

где общая сумма квадратов:

$$Q = \sum_i \sum_j \sum_k (x_{ijk} - \bar{x})^2,$$

сумма квадратов, учитывающая влияние фактора A :

$$Q_A = nr \sum_j (\bar{x}_{0j} - \bar{x})^2;$$

сумма квадратов, учитывающая влияние фактора B :

$$Q_B = nl \sum_k (\bar{x}_{0k} - \bar{x})^2;$$

сумма квадратов, учитывающая взаимодействие факторов A и B :

$$Q_{AB} = n \sum_j \sum_k (\bar{x}_{jk} - x_{0j} - x_{k0} + \bar{x})^2;$$

остаточная сумма квадратов:

$$Q_e = \sum_i \sum_j \sum_k (x_{ijk} - \bar{x}_{jk})^2;$$

соответствующие дисперсии:

$$S^2 = \frac{Q}{nlr - 1},$$

$$S_A^2 = \frac{Q_A}{l - 1},$$

$$S_B^2 = \frac{Q_B}{r - 1},$$

$$S_{AB}^2 = \frac{Q_{AB}}{(l - 1)(r - 1)},$$

$$S_e^2 = \frac{Q_e}{lr(n - 1)}.$$

Проверка нулевых гипотез осуществляется с использованием статистик Фишера:

$$F_A = \frac{S_A^2}{S_e^2},$$

$$F_B = \frac{S_B^2}{S_e^2},$$

$$F_{AB} = \frac{S_{AB}^2}{S_e^2},$$

которые сравниваются с соответствующими квантилями. Например, гипотеза H_0 об отсутствии влияния взаимодействия факторов A и B на результативный признак X принимается, если

$$F_{AB} < F_{1-\alpha}[(l-1)(r-1), lr(n-1)].$$

Результаты оформляются в виде таблицы.

| Источник дисперсии | Сумма квадратов | Число степеней свободы | Дисперсия | Выборочное значение статистики Фишера |
|---------------------|-----------------|------------------------|------------|---------------------------------------|
| Фактор A | Q_A | $l - 1$ | S_A^2 | F_A |
| Фактор B | Q_B | $r - 1$ | S_B^2 | F_B |
| Взаимодействие AB | Q_{AB} | $(l - 1)(r - 1)$ | S_{AB}^2 | F_{AB} |
| Остаток | Q_e | $rl(n - 1)$ | S_e^2 | |
| Общая | Q | $lrn - 1$ | S^2 | |

Алгоритм трехфакторного дисперсионного анализа аналогичен двухфакторному. Оценивается влияние факторов A , B , C , их попарного взаимодействия AB , BC , AC и общего взаимодействия ABC на результативный признак X . Фактор A имеет l уровней, фактор B – r уровней, фактор C – q

уровней. При каждом сочетании уровней проводятся по n измерений, то есть общее число измерений $nlrq$.

Таблица трехфакторного анализа имеет вид:

| Источник дисперсии | Сумма квадратов | Число степеней свободы | Дисперсия | Выборочное значение статистики Фишера |
|----------------------|-----------------|----------------------------|-------------|---------------------------------------|
| Фактор A | Q_A | $l - 1$ | S_A^2 | F_A |
| Фактор B | Q_B | $r - 1$ | S_B^2 | F_B |
| Фактор C | Q_C | $q - 1$ | S_C^2 | F_C |
| Взаимодействие AB | Q_{AB} | $(l - 1)(r - 1)$ | S_{AB}^2 | F_{AB} |
| Взаимодействие BC | Q_{BC} | $(r - 1)(q - 1)$ | S_{BC}^2 | F_{BC} |
| Взаимодействие AC | Q_{AC} | $(l - 1)(q - 1)$ | S_{AC}^2 | F_{AC} |
| Взаимодействие ABC | Q_{ABC} | $(l - 1)(r - 1) * (q - 1)$ | S_{ABC}^2 | F_{ABC} |
| Остаток | Q_e | $lrq(n - 1)$ | S_e^2 | |
| Общая | Q | $lrqn - 1$ | S^2 | |

Для проверки нулевой гипотезы, например, об отсутствии влияния общего взаимодействия ABC значение статистики Фишера

$$F_{ABC} = \frac{S_{ABC}^2}{S_e^2} = \frac{\frac{1}{(l - 1)(r - 1)(q - 1)} Q_{ABC}}{\frac{1}{lrq(n - 1)} Q_e}$$

сравнивается с квантилью

$$F_{1-\alpha}[(l - 1)(r - 1)(q - 1), lrq(n - 1)]$$